

《数据挖掘与机器学习》课程设计说明书

本文档的内容还会不断更新中...

课程设计数据将在百度云盘中不断更新：

链接：<https://pan.baidu.com/s/1rQ3w0xkeMlCvldKwuwEHeA>

提取码：krv6

一、课程设计要求

1. 课程设计最多 2 人 1 组，最晚 19 周周二交课程设计文档电子版；
2. 采用多种机器学习的技术，最好是深度学习框架，如 PyTorch、TensorFlow，其中 TensorFlow 则要求 2.5+；
3. 最好尝试使用新的深度网络模型，如 Efficient，ResNet，YOLO 等，并采用官方数据集；
4. 设计题目分两种，一种老师指定题目，要求尽量按老师描述的需求完成；另一种则是自拟题目，或从老师给的参考题目中选择，选择的题目需要有一定工作量；
5. 所完成的学习系统需有一定的方法与模型说明，需要选择较大多类别的数据集，可以使识别、检测等任务，一般需要给出学习效果的分析，如混淆矩阵、准确率、精确率、召回率，损失函数并要求给出错误分类的部分数据；
6. 课程设计的代码挂在码云或 GitHub 或者单独打包，课程报告须提供该链接；
7. 部分题目若由两个同学分别完成，需明确两人的任务，要有独立分工，不要任务失衡。
8. 严禁抄袭，作 0 分处理。
9. 初定在 15-17 周，每周各一天来进行答辩，合作的同学必须同时参加。

二、课程报告写作要求

1. 电子版文件命名为“学号_姓名_课程设计题目.doc”，如“202321314202_张三_博客网站系统.doc”。**设计报告模板**参照附件下载，需严格按照论文格式要求撰写，最后要上传到学习通上给出的上传链接。
2. 设计报告**正文篇幅**在 14 页以上，核心代码片段不超过 2 页！
3. 文档绘图采用 Visio、SmartDraw 等专业软件。
4. 课程设计请按模板文件进行。
5. 可以多人合作一个题目，但必须分别承担不同的模块，有明确的分工，每人上交不同的文档。
6. 摘要部分要写清楚老师检查时要求增加的功能（**切记**），增加的功能要在论文中显著标出，并用不同颜色字体显示；
7. 最后需同时递交电子版与纸质版，**需单独附上代码文件打包**，纸质版都交到实验室。

三、指定的题目

1. 7 种甜玉米种子的分类

2. 电路板故障检测
3. 毕业生就业数据分析
4. 基于土壤光谱数据的元素分析
5. 人脸识别
6. 土壤种植农作物分类
7. 叶子病害识别
8. 基于无人机航拍的柑橘树识别
9. CIFAR-100 数据集的识别
10. 垃圾分类
11. 花卉识别
12. 猴子识别
13. 鸟类识别
14. 宠物识别
15. 花卉识别 2
16. 失误识别
17. 汽车识别
18. 口罩检测
19. 数据分析达人赛 3-汽车产品聚类分析


选择以上题目的同学，可找老师了解相关需求，数据将会云盘中陆续放出，题目类别也将会不断更新...

1、甜玉米种子的分类

已有 7 种甜玉米种子的图片共 14 张，其中每种甜玉米种子包含有胚面与无胚面 2 张图片，每张图片又包含 64 粒玉米。

参考做法：首先利用图像处理的手段，利用颜色如亮度进行 OTSU 阈值分割，提取出每粒玉米的单张图像，然后提取玉米图像上的特征（如颜色、形状、纹理特征等，纹理特征可以采用灰度共生矩阵生成，或者 LBP、HOG 等），最后应用多个分类模型（SVM、随机森林等）进行分类判别。

如果采用深度神经网络，也可以不需要提取特征。



2、电路板故障检测

随着移动电子和 IOT 的大量普及，PCB（印刷电路板）需求量有了显著提升。而在 PCB 生产过程中，往往会因为设备问题、流程问题出现一定概率的故障，轻则接触不良，功能缺陷，影响使用体验；重则引发火情，严重影响人民生命、财产安全。目前 PCB 线路常规线宽为 10mil（约 0.254mm），PCB 质检通常由产线工人使用显微放大镜在强光下目检，效率较低，且长期在强光显微镜下观察 PCB 板容易对眼睛产生伤害，同时也容易疲劳出错。故提出使用较为低廉的边端算力摄像头系统实现这一任务。

现有多种电路板故障的图片，故障可分 7 大类，同学可根据自己能力选择其中 1 类或几类进行检测。其中有个 xml 文件，讲述了每个缺陷点的位置。常用的目标检测网络，如 YOLO 系列，CenterNet，SSD，Faster RCNN 等。

直接下载链接：<https://aistudio.baidu.com/aistudio/datasetdetail/73416>

3、毕业生就业数据分析

现有 2020 届就业信息.xlsx 与 2020 届生源信息表.xlsx 两个文件，需要做出就业质量与就业群体两个维度的就业分析。需要自己分析表格的属性意义进行以下数据统计（数据可能有脏数据）

- （1）给出全校整体的本科、硕士的就业率；具体每个学院的本科就业率，每个专业的本科就业率。（就业率包括聘用、升学、自主创业、入伍、公务员等等）
- （2）给出本科生的就业单位性质占比：机关事业单位、国企、民企、外资、基层项目、灵活就业、社会组织等结构。
- （3）给出本科生的学院-专业的薪酬分布。
- （4）给出不同性别的学院-专业的薪酬分布。
- （5）给出本科就业同学落在大湾区、省内、省外、国外的分布情况。
- （6）给出本科各个专业考研学校的前三所高效。

4、基于土壤光谱数据的元素分析

利用红外光谱对土壤样品进行快速、低成本分析，为预测未采样地点的土壤功能特性提供了新的途径。土壤功能特性是指与土壤支持基本生态系统服务的能力有关的特性，如初级生产力、养分和水分保持以及对土壤侵蚀的抵抗能力。土壤功能特性的数字绘图，特别是在非洲等数据稀少的地区，对于规划可持续农业集约化和自然资源管理非常重要。

在样品制备过程中，测量土壤样品吸收的光量，测量波长范围内的数百个红外特定波段。与传统的化学测量方法相比，红外光谱检测快速，其测量时间通常在大约 30 秒内完成，并且化学测量过程比较缓慢，用到的化学用品也相对昂贵。

土壤的 5 个成分分别是 Ca, P, pH, SOC, Sand 含量, 在 Excel 表的最后五列, 详细 Excel 数据说明如下:

PIDN: unique soil sample identifier

SOC: Soil organic carbon

pH: pH values

Ca: Mehlich-3 extractable Calcium

P: Mehlich-3 extractable Phosphorus

Sand: Sand content

m7497.96 - m599.76: There are 3,578 mid-infrared absorbance measurements. For example, the "m7497.96" column is the absorbance at wavenumber 7497.96 cm-1 (红外波段长度). We suggest you to remove spectra CO2 bands which are in the region m2379.76 to m2352.76, but you do not have to.

Depth: Depth of the soil sample (2 categories: "Topsoil", "Subsoil")

数据文件, training.csv, sorted_test.csv。

请建立数据回归模型, 通过 3578 个中红外光谱反射数据, 对土壤进行成分预测。

5、人脸识别

ORL Dataset 是剑桥大学 AT&T 实验室制作的人脸数据集, 其包含从 1992 年 4 月到 1994 年 4 月期间实验室成员的人脸图像。该数据集的图像分为 40 个不同主题, 其中每个主题包含 10 幅图像。

请划分不同训练集与测试集, 完成识别任务。

6、土壤种植农作物分类

精准农业是当今的潮流。它帮助农民对农业策略做出明智的决定。在这里, 有一个印度的土壤数据集, 该数据集允许用户建立一个预测模型, 根据各种参数推荐在特定农场种植的最适合的作物。

Excel 数据中 (Crop_recommendation.xlsx)

N - ratio of Nitrogen content in soil

P - ratio of Phosphorous content in soil

K - ratio of Potassium content in soil

temperature - temperature in degree Celsius

humidity - relative humidity in %

ph - ph value of the soil

rainfall - rainfall in mm

label- 表示适合种植的作物

请划分不同训练集与测试集, 完成分类

7、叶子病害识别

数据集有 61 个分类（按“物种-病害-程度”分），10 个物种，27 种病害（其中 24 个病害有分一般和严重两种程度），10 个健康分类，47637 张图片。每张图包含一片农作物的叶子，叶子占据图片主要位置。数据集随机分为训练（70%）、验证（10%）、测试 A（10%）与测试 B（10%）四个子数据集。训练集和验证集包含图片和标注的 json 文件，json 文件中包含每一张图片和对应的分类 ID。

由于数据集较大，学生可根据自己能力只识别其中 1 类物种的所属病害。

Label id	Label name(标签名)
0	apple healthy（苹果健康）
1	Apple_Scab general（苹果黑星病一般）
2	Apple_Scab serious（苹果黑星病严重）
3	Apple Frogeye Spot（苹果灰斑病）
4	Cedar Apple Rust general（苹果雪松锈病一般）
5	Cedar Apple Rust serious（苹果雪松锈病严重）
6	Cherry healthy（樱桃健康）
7	Cherry_Powdery Mildew general（樱桃白粉病一般）
8	Cherry_Powdery Mildew serious（樱桃白粉病严重）
9	Corn healthy（玉米健康）
10	Cercospora zeaemaydis Tehon and Daniels general（玉米灰斑病一般）
11	Cercospora zeaemaydis Tehon and Daniels serious（玉米灰斑病严重）
12	Puccinia polysora general（玉米锈病一般）
13	Puccinia polysora serious（玉米锈病严重）
14	Corn Curvularia leaf spot fungus general（玉米叶斑病一般）
15	Corn Curvularia leaf spot fungus serious（玉米叶斑病严重）
16	Maize dwarf mosaic virus（玉米花叶病毒病）
17	Grape healthy（葡萄健康）
18	Grape Black Rot Fungus general（葡萄黑腐病一般）
19	Grape Black Rot Fungus serious（葡萄黑腐病严重）
20	Grape Black Measles Fungus general（葡萄轮斑病一般）
21	Grape Black Measles Fungus serious（葡萄轮斑病严重）
22	Grape Leaf Blight Fungus general（葡萄褐斑病一般）
23	Grape Leaf Blight Fungus serious（葡萄褐斑病严重）
24	Citrus healthy（柑桔健康）

25	Citrus Greening June general (柑桔黄龙病一般)
26	Citrus Greening June serious (柑桔黄龙病严重)
27	Peach healthy (桃健康)
28	Peach_Bacterial Spot general (桃疮痂病一般)
29	Peach_Bacterial Spot serious (桃疮痂病严重)
30	Pepper healthy (辣椒健康)
31	Pepper scab general (辣椒疮痂病一般)
32	Pepper scab serious (辣椒疮痂病严重)
33	Potato healthy (马铃薯健康)
34	Potato_Early Blight Fungus general (马铃薯早疫病一般)
35	Potato_Early Blight Fungus serious (马铃薯早疫病严重)
36	Potato_Late Blight Fungus general (马铃薯晚疫病一般)
37	Potato_Late Blight Fungus serious (马铃薯晚疫病严重)
38	Strawberry healthy (草莓健康)
39	Strawberry_Scorch general (草莓叶枯病一般)
40	Strawberry_Scorch serious (草莓叶枯病严重)
41	Tomato healthy (番茄健康)
42	tomato powdery mildew general (番茄白粉病一般)
43	tomato powdery mildew serious (番茄白粉病严重)
44	Tomato Bacterial Spot Bacteria general (番茄疮痂病一般)
45	Tomato Bacterial Spot Bacteria serious (番茄疮痂病严重)
46	Tomato_Early Blight Fungus general (番茄早疫病一般)
47	Tomato_Early Blight Fungus serious (番茄早疫病严重)
48	Tomato_Late Blight Water Mold general (番茄晚疫病菌一般)
49	Tomato_Late Blight Water Mold serious (番茄晚疫病菌严重)
50	Tomato_Leaf Mold Fungus general (番茄叶霉病一般)
51	Tomato_Leaf Mold Fungus serious (番茄叶霉病严重)
52	Tomato Target Spot Bacteria general (番茄斑点病一般)
53	Tomato Target Spot Bacteria serious (番茄斑点病严重)
54	Tomato_Septoria Leaf Spot Fungus general (番茄斑枯病一般)
55	Tomato_Septoria Leaf Spot Fungus serious (番茄斑枯病严重)
56	Tomato Spider Mite Damage general (番茄红蜘蛛损伤一般)
57	Tomato Spider Mite Damage serious (番茄红蜘蛛损伤严重)

58	Tomato YLCV Virus general（番茄黄化曲叶病毒病一般）
59	Tomato YLCV Virus serious（番茄黄化曲叶病毒病严重）
60	Tomato Tomv（番茄花叶病毒病）

一般先写程序，根据 JSON 文件把 60 种病害进行文件归档或重新编号，如 04-1021（表示第 4 类别的第 1021 张叶片图片）

8、基于无人机航拍的柑橘树识别

现有从化果园无人机航拍图片若干，请从图中识别其中的柑橘树。

一般需要先 LabelMe 进行柑橘树标记，然后学习训练后，识别柑橘树所在区域，通过 IOU（交并比）来给出识别效果。

一般采用 Yolo，CenterNet，SSD 等网络进行识别与定位。

9、CIFAR-100 数据集的识别

CIFAR100 数据集有 100 个类。每个类有 600 张大小为 32×32 的彩色图像，其中 500 张作为训练集，100 张作为测试集。对于每一张图像，它有 fine_labels 和 coarse_labels 两个标签，分别代表图像的细标签和粗标签，对应下图中的 classes 和 superclass。

Superclass

aquatic mammals
fish
flowers
food containers
fruit and vegetables
household electrical devices
household furniture
insects
large carnivores
large man-made outdoor things
large natural outdoor scenes
large omnivores and herbivores
medium-sized mammals
non-insect invertebrates
people
reptiles
small mammals
trees
vehicles 1
vehicles 2

Classes

beaver, dolphin, otter, seal, whale
aquarium fish, flatfish, ray, shark, trout
orchids, poppies, roses, sunflowers, tulips
bottles, bowls, cans, cups, plates
apples, mushrooms, oranges, pears, sweet peppers
clock, computer keyboard, lamp, telephone, television
bed, chair, couch, table, wardrobe
bee, beetle, butterfly, caterpillar, cockroach
bear, leopard, lion, tiger, wolf
bridge, castle, house, road, skyscraper
cloud, forest, mountain, plain, sea
camel, cattle, chimpanzee, elephant, kangaroo
fox, porcupine, possum, raccoon, skunk
crab, lobster, snail, spider, worm
baby, boy, girl, man, woman
crocodile, dinosaur, lizard, snake, turtle
hamster, mouse, rabbit, shrew, squirrel
maple, oak, palm, pine, willow
bicycle, bus, motorcycle, pickup truck, train
lawn-mower, rocket, streetcar, tank, tractor

下载好的 CIFAR100 数据集解压后, 可以看到一共有四个文件, 分别是: meta、train、test、file.txt~

文件读取方法:

```
import pickle
def unpickle(file):
    with open(file, 'rb') as fo:
        dict = pickle.load(fo, encoding='latin1')
    return dict

trainobj = unpickle(r'D:\Data\cifar-100-python\train')    # 读取训练文件
for item in trainobj:
    print(item)
```

输出:

```
filenames
batch_label
fine_labels
coarse_labels
data
```

我们获取到字典格式的信息, 打印后发现字典中共有 filenames、batch_label、fine_labels、coarse_labels 和 data 这五个 key。分别是图像名称、batch_label、细粒度标签、粗粒度标签、图像表示的信息。

通过以下方法读取数据

```
x_train = trainobj['data']
y_train = trainobj['fine_labels']    # 细标签
y_train2 = trainobj['coarse_labels'] # 粗标签
```

请用神经网络或深度学习网络分别 对粗标签与细标签建立分类模型。

10、垃圾分类

垃圾分类是对垃圾收集处置传统方式的改革, 是对垃圾进行有效处置的一种科学管理方法。人们面对日益增长的垃圾产量和环境状况恶化的局面, 如何通过垃圾分类管理, 最大限度地实现垃圾资源利用, 减少垃圾处置的数量, 改善生存环境状态, 是当前世界各国共同关注的迫切问题。 2019 年 6 月 25 日, 固体废物污染环境防治法修订草案初次提请全国人大常委会审议。草案对“生活垃圾污染环境的防治”进行了专章规定。2019 年 9 月, 为深入贯彻落实习近平总书记关于垃圾分类工作的重要指示精神, 推动全国公共机构做好生活垃圾分类工作, 发挥率先示范作用, 国家机关事务管理局印发通知, 公布《公共机构生活垃圾分类

类工作评价参考标准》，并就进一步推进有关工作提出要求。2019 年 12 月 6 日，垃圾分类入选“2019 年中国媒体十大流行语”。

垃圾种类：

➤可回收物

可回收物主要包括废纸、塑料、玻璃、金属和布料五大类。

(1) 废纸：主要包括报纸、期刊、图书、各种包装纸等。但是，要注意纸巾和厕所纸由于水溶性太强不可回收。

(2) 塑料：各种塑料袋、塑料泡沫、塑料包装（快递包装纸是其他垃圾/干垃圾）、一次性塑料餐盒餐具、硬塑料、塑料牙刷、塑料杯子、矿泉水瓶等。玻璃：主要包括各种玻璃瓶、碎玻璃片、暖瓶等。（镜子是其他垃圾/干垃圾）

(3) 金属物：主要包括易拉罐、罐头盒等。

(4) 布料：主要包括废弃衣服、桌布、洗脸巾、书包、鞋等。

这些垃圾通过综合处理回收利用，可以减少污染，节省资源。如每回收 1 吨废纸可造好纸 850 公斤，节省木材 300 公斤，比等量生产减少污染 74%；每回收 1 吨塑料饮料瓶可获得 0.7 吨二级原料；每回收 1 吨废钢铁可炼好钢 0.9 吨，比用矿石冶炼节约成本 47%，减少空气污染 75%，减少 97% 的水污染和固体废物。

➤其他垃圾

其他垃圾（上海称干垃圾）包括除上述几类垃圾之外的砖瓦陶瓷、渣土、卫生间废纸、纸巾等难以回收的废弃物及尘土、食品袋（盒）。

(1) 卫生纸：厕纸、卫生纸遇水即溶，不算可回收的“纸张”，类似的还有烟盒等。

(2) 果壳：在垃圾分类中，“果壳瓜皮”的标识就是花生壳，的确属于厨余垃圾。家里用剩的废弃食用油，也归类在“厨余垃圾”。

(3) 尘土：在垃圾分类中，尘土属于“其它垃圾”，但残枝落叶属于“厨余垃圾”，包括家里开败的鲜花等。

采取卫生填埋可有效减少对地下水、地表水、土壤及空气的污染。

➤厨余垃圾

厨余垃圾（上海称湿垃圾）包括剩菜剩饭、骨头、菜根菜叶、果皮等食品类废物。经生物技术就地处理堆肥，每吨可生产 0.6~0.7 吨有机肥料。

➤有害垃圾

有害垃圾含有对人体健康有害的重金属、有毒的物质或者对环境造成现实危害或者潜在危害的废弃物。包括电池、荧光灯管、灯泡、水银温度计、油漆桶、部分家电、过期药品及其容器、过期化妆品等。

这些垃圾一般使用单独回收或填埋处理。


数据集总共有 40 种垃圾，可以选择以上若干大类进行分类，

解压后有一个 train_data 目录，包含了全部图片数据，然后还有 0-39 等 40 个目录，单独包含了 train_data 目录出现的图片。由于分辨率不一致，需要些程序统一分辨率。

11、花卉识别

数据集下载: <https://www.robots.ox.ac.uk/~vgg/data/flowers/17/17flowers.tgz>

具有 17 类花卉数据集, 类别分别是 Buttercup, Colls' Foot, Daffodil, Daisy, Dandelion, Fritillary, Iris, Pansy, Sunflower, Windflower, Snowdrop, Lily Valley, Bluebell, Crocus, Tigerlily, Tulip, Cowslip, 每个类别有 80 张图片。如下图所示:




对数据集进行分类，80%训练集，20%测试集。

可提取颜色特征进行神经网络建模，或者直接采用深度网络训练等。
相应数据提取代码，老师将发布在云盘上。（不用 AlexNet 与 Lenet）

12、猴子识别

现有 kaggle 上的猴子数据集，包含两个文件：训练集和验证集。每个文件夹包含 10 个标记为 n0-n9 的猴子。图像尺寸为 400x300 像素或更大，并且为 JPEG 格式（近 1400 张图像）。



Label	Latin Name	Common Name	Train Images	Validation Images
n0	alouatta_palliata	mantled_howler	131	26
n1	erythrocebus_patas	patas_monkey	139	28
n2	cacajao_calvus	bald_uakari	137	27
n3	macaca_fuscata	japanese_macaque	152	30
n4	cebuella_pygmea	pygmy_marmoset	131	26
n5	cebus_capucinus	white_headed_capuchin	141	28
n6	mico_argentatus	silvery_marmoset	132	26
n7	saimiri_sciureus	common_squirrel_monkey	142	28
n8	aotus_nigriceps	black_headed_night_monkey	133	27
n9	trachypithecus_johnii	nilgiri_langur	132	26

请完成 10 种猴子的识别任务。

13、鸟类识别

包含 200 种鸟类（主要为北美洲鸟类）照片的图像数据集，可用于图像识别工作。分类数量：200；图片数量：11788；平均每张图片含有的标注数量：

15 个局部位置，312 个二进制属性，1 个边框框。

14、宠物识别

包含 37 种宠物类别的图像数据集，每个类别约有 200 张图像。这些图像在比例、姿势以及光照方面有着丰富的变化。本数据集也可以用于目标检测定位。

15、花卉识别 2

包含 102 种花类的图像数据集（主要是一些英国常见的花类），每个类别包含 40—258 张图像。这些图像在比例、姿势以及光照方面有着丰富的变化。

16、食物识别

包含 101 种食品类别的图像数据集，共有 101000 张图像，平均每个类别拥有 250 张测试图像和 750 张训练图像。训练图像未经过数据清洗。所有图像都已经重新进行了尺寸缩放，最大边长达到了 512 像素。

下载地址：<https://s3.amazonaws.com/fast-ai-imageclas/food-101.tgz>

17、汽车识别

包含 196 种汽车类别的图像数据集，共有 16185 张图像，分别为 8144 张训练图像和 8041 张测试图像，每个类别的图像类型比例基本上都是五五开。本数据集的类别主要基于汽车的牌子、车型以及年份进行划分。

下载地址：<https://s3.amazonaws.com/fast-ai-imageclas/stanford-cars.tgz>

18、口罩识别

包含 137,016 张高质量口罩人脸图像的大型数据集，可以被看作是一个基准数据集，用于创建与口罩佩戴分析相关的机器学习模型；特别是是否佩戴口罩和是否佩戴准确。

口罩人脸数据集的提出目的：

- i) 检测人们是否戴了口罩
- ii) 检测人们是否正确佩戴口罩(例如，在机场入口处或人群中)。

每张图片只有一个人，需要判断其是否佩戴口罩，或正确佩戴口罩。

正确佩戴数据集：

https://esigelec-my.sharepoint.com/:f:/g/personal/cabani_esigelec_fr/Ev3GdnQSyzxPjyzU5ElHqagBlkRCaKnnCI85iX-d1L4OHA?e=G7uaYV

错误佩戴数据集：

https://esigelec-my.sharepoint.com/:f:/g/personal/cabani_esigelec_fr/EirjS8ew

[7-5LnO8I56Uk63wBKeBwSlukFBFBaO8N25wn3g?e=Ho1jHG](https://tianchi.aliyun.com/competition/gameList/coupleList)

19、口罩检测

有 9240 个戴口罩数据，需要检测图片中哪些人带了口罩，哪些人没有带，并给出位置。数据再网盘上，每个样本对应一张图片与文本文件，文本文件有该图片对应带口罩与没戴口罩的人的数据，对应其 YOLO 的输入标注格式。

20、数据分析达人赛 3-汽车产品聚类分析

聚类分析是常用的数据分析方法之一，不仅可以帮助我们对用户进行分组，还可以帮我们对产品进行分组（比如竞品分析）

数据包括了 205 款车的 26 个字段

To Do: 请你对该汽车数据进行聚类分析，并找到 vokswagen 汽车的竞品

<https://tianchi.aliyun.com/notebook-ai/detail?spm=5176.12281897.0.0.1c2039a9Ch5gje&postId=198337>

四、自拟题目的参考

除了老师发布的参考题目，同学们还可以参考各大人工智能或机器学习竞赛的赛题，或者一些传统机器学习的常用数据集进行学习分类。要求工作量相当，如遇到复杂数据集，如多种分类的，可减少分类类别

1. 天池大数据竞赛: <https://tianchi.aliyun.com/competition/gameList/coupleList>;
<https://tianchi.aliyun.com/competition/gameList/algorithmList>;

2. kaggle 全球机器学习竞赛: 有大量比赛 <https://www.kaggle.com/competitions> 与数据集 <https://www.kaggle.com/datasets>; 入门 <https://zhuanlan.zhihu.com/p/25686876>

3. 和鲸数据竞赛: <https://www.heywhale.com/home/competition>

4. 计算机视觉竞赛: <https://www.52cv.net/?cat=56>

5. datafountain 大赛: <https://www.datafountain.cn/competitions>

6. FlyAI 竞赛平台: <https://www.flyai.com/>

7. biendata: <https://www.biendata.xyz/>

8. MS COCO: <https://cocodataset.org/#home>